Report: Translation Module

(Machine Translation - MT)

AuraTranslate Edge - OneVoice AI Challenge 2026

Lê Gia Khánh - Gia Sư Đỉnh Cao

Contents

1 Giới thiệu **2**
1.1 Project AuraTranslate Edge . . . 2
1.2 Module Machine Translation (MT) . . . 2
1.3 GitHub mã nguồn . . . 2

2 Lựa chọn Model **2**
2.1 Thí nghiệm . . . 2
2.2 Kết luận . . . 2

3 Model NLLB **2**
3.1 Kiến trúc Model . . . 2
3.2 Quantize và Deploy . . . 2
3.3 Những khó khăn và Cách khắc phục . . . 2
3.4 Mã nguồn và Cách triển khai . . . 2
3.5 Kết quả từ Qualcomm AI Hub . . . 2

4 Demo MT Dashboard **2**
4.1 Mã nguồn và Cách triển khai . . . 2
4.2 Nhận xét kết quả . . . 2

5 Pipeline Integration **2**
5.1 Các Modules còn lại . . . 2
5.2 Hướng hợp nhất Pipeline . . . 3

1 Giới thiệu

1.1 Project AuraTranslate Edge

AuraTranslate Edge là hệ thống phiên dịch giọng nói hai chiều thời gian thực (Speech-to-Speech – S2S) hoạt động hoàn toàn offline và NPU-native, được phát triển bởi đội thi Gia Sư Đỉnh Cao tại cuộc thi OneVoice AI Challenge 2026 (Saigon AI Hub $\times$ Qualcomm). Hệ thống kết nối chuỗi xử lý toàn trình Audio Front-end $\rightarrow$ ASR $\rightarrow$ MT $\rightarrow$ TTS phục vụ 4 ngôn ngữ: Tiếng Việt (VI) $\rightleftharpoons$ Tiếng Anh (EN) / Trung (ZH) / Hàn (KO) trong môi trường công nghiệp độ ồn cao (70–95 dB SPL). Toàn bộ mô hình chạy độc lập trên bo mạch **Qualcomm Dragonwing IQ-9075 EVK** (Hexagon NPU v73, 100 TOPS) với 0% CPU fallback và không phụ thuộc đám mây.

1.2 Module Machine Translation (MT)

1.3 GitHub mã nguồn

Mã nguồn dự án được công khai tại:
https://github.com/LGKAI/AuraTranslateEdge-OneVoice

2 Lựa chọn Model

2.1 Thí nghiệm

2.2 Kết luận

3 Model NLLB

3.1 Kiến trúc Model

3.2 Quantize và Deploy

3.3 Những khó khăn và Cách khắc phục

3.4 Mã nguồn và Cách triển khai

3.5 Kết quả từ Qualcomm AI Hub

4 Demo MT Dashboard

4.1 Mã nguồn và Cách triển khai

4.2 Nhận xét kết quả

5 Pipeline Integration

5.1 Các Modules còn lại

5.2 Hướng hợp nhất Pipeline

Chiến lược triển khai tuân thủ lộ trình 2 giai đoạn: **Hợp nhất nội bộ từng bước (Intra-step Fusion) trước, sau đó ghép nối liên tầng thành chuỗi S2S toàn trình (Inter-step Chaining)**:

1. Pha 1 – Hợp nhất Nội bộ Từng Bước (Intra-step Fusion):

- *Khối ASR (Đã hoàn tất):* Hợp nhất toàn bộ Fbank DSP, Encoder, CTC Head và bộ Detokenizer UTF-8 thành đồ thị tĩnh duy nhất chạy 100% NPU.
- *Khối MT (Đã hoàn tất):* Tĩnh hóa kích thước ngữ cảnh và nhúng bảng tra cứu Language ID vào đồ thị QNN DLC của NLLB-200.
- *Khối TTS:* Đóng gói liên hoàn Text Encoder, bộ tạo phổ Mel và Vocoder thành một chuỗi tính toán nội bộ duy nhất, xuất thẳng sóng âm PCM 16 kHz.

2. Pha 2 – Ghép nối Toàn trình & Kiểm định Liên tầng (Inter-step Chaining):

$$\text{Audio Vào} \xrightarrow{\text{Step 0: Lọc nhiễu}} \text{Step 1: ASR} \xrightarrow{\text{Step 2: Dịch MT}} \text{Step 3: Tổng hợp TTS} \rightarrow \text{Audio Ra}$$

- *Truyền dữ liệu Zero-copy:* Các bước trao đổi dữ liệu bất đồng bộ qua bộ đệm tuần hoàn (*Circular Buffer*) trên RAM LPDDR5 theo mô hình Producer–Consumer, triệt tiêu độ trễ I/O.
- *Cơ chế kiểm soát chất lượng liên tầng:* Tự động hạ chữ thường (`hyp.lower()`) từ Zipformer trước khi nạp vào MT để bảo toàn mã hóa BPE; đồng thời dùng SenseVoice nhận diện ngược âm thanh TTS để tự động sinh lại nếu phát hiện lỗi lặp âm tiết.
- *Ngân sách độ trễ toàn trình (Latency Budget):* Tổng thời gian xử lý toàn chuỗi chỉ tốn 1.0–1.8 giây (ASR ~ 0.2 s, MT ~ 0.6 s, TTS ~ 0.5 s), hoàn toàn nằm dưới giới hạn khắt khe ≤ 3.0 giây của OneVoice AI Challenge.