Report: Translation Module

(Machine Translation - MT)

AuraTranslate Edge - OneVoice AI Challenge 2026

Lê Gia Khánh - Gia Sư Đỉnh Cao

Contents

1 Giới thiệu **2**
1.1 Project AuraTranslate Edge . . . 2
1.2 Module Machine Translation (MT) . . . 2
1.3 GitHub mã nguồn . . . 2

2 Lựa chọn Model **2**
2.1 Thí nghiệm . . . 2
2.2 Kết luận . . . 3

3 Model NLLB **3**
3.1 Kiến trúc Model . . . 3
3.2 Quantize và Deploy . . . 4
3.3 Những khó khăn và Cách khắc phục . . . 5
3.4 Mã nguồn và Cách triển khai . . . 6
3.5 Kết quả từ Qualcomm AI Hub . . . 6

4 Demo MT Dashboard **8**
4.1 Mã nguồn và Cách triển khai . . . 8
4.2 Nhận xét kết quả . . . 9

5 Pipeline Integration **9**
5.1 Các Modules còn lại . . . 9
5.2 Hướng hợp nhất Pipeline . . . 10

1 Giới thiệu

1.1 Project AuraTranslate Edge

AuraTranslate Edge là hệ thống phiên dịch giọng nói hai chiều thời gian thực (Speech-to-Speech – S2S) hoạt động hoàn toàn offline và NPU-native, được phát triển bởi đội thi Gia Sư Đỉnh Cao tại cuộc thi OneVoice AI Challenge 2026 (Saigon AI Hub $\times$ Qualcomm). Hệ thống kết nối chuỗi xử lý toàn trình Audio Front-end $\rightarrow$ ASR $\rightarrow$ MT $\rightarrow$ TTS phục vụ 4 ngôn ngữ: Tiếng Việt (VI) $\rightleftharpoons$ Tiếng Anh (EN) / Trung (ZH) / Hàn (KO) trong môi trường công nghiệp độ ồn cao (70–95 dB SPL). Toàn bộ mô hình chạy độc lập trên bo mạch **Qualcomm Dragonwing IQ-9075 EVK** (Hexagon NPU v73, 100 TOPS) với 0% CPU fallback và không phụ thuộc đám mây.

1.2 Module Machine Translation (MT)

Mô-đun MT (Step 2) đảm nhận phiên dịch hai chiều thời gian thực giữa Tiếng Việt và 3 ngoại ngữ (VI $\rightleftharpoons$ EN / ZH / KO – 6 hướng dịch) bằng kiến trúc đồ thị tĩnh tối ưu cho NPU:

- **NLLB-200-distilled-600M (Đồ thị tĩnh $S = 32, T = 16$):** Đóng gói toàn bộ Encoder và chuỗi giải mã Decoder vào một đồ thị tĩnh duy nhất (*Single Static DAG*) với $S = 32$ (chiều dài tối đa câu nguồn) và $T = 16$ (số bước giải mã / độ dài tối đa câu đích), triệt tiêu hoàn toàn vòng lặp sinh token trên CPU. Từ điển được cắt tỉa từ 256k xuống 139k tokens để nén mô hình dưới 2.0 GB.
- **Thực thi 100% NPU trên Qualcomm Dragonwing IQ-9075:** Biên dịch Native FP16 với 100% toán tử chạy trên Hexagon NPU v73 HTP (0% CPU fallback, 7.617 layers). Mô hình đạt độ trễ suy luận **215.87 ms**/câu, RAM đỉnh **6.59 MB** và khớp 100% từng token so với bản gốc CPU.

1.3 GitHub mã nguồn

Mã nguồn dự án được công khai tại:
https://github.com/LGKAI/AuraTranslateEdge-OneVoice

2 Lựa chọn Model

2.1 Thí nghiệm

Nhóm tiến hành thực nghiệm đối đầu trực tiếp giữa ba mô hình tiềm năng: **NLLB-200-distilled-600M**, **Qwen3-0.6B** và **Qwen3-1.7B** trên tập dữ liệu chuẩn **FLORES-200** (30 câu ngẫu nhiên $\times$ 6 chiều dịch thuật qua lại giữa Tiếng Việt, Tiếng Anh, Tiếng Trung và Tiếng Hàn). Các ứng viên được đánh giá toàn diện qua điểm số chất lượng dịch thuật (**BLEU**) và tốc độ suy luận thực tế (giây/câu).

(Ghi chú: Chiều vi $\rightarrow$ ko có điểm BLEU bề mặt thấp do tiếng Hàn là ngôn ngữ chắp dính (agglutinative) với hệ thống trợ từ và kính ngữ phức tạp, khiến việc so khớp n-gram bị phạt nặng dù bản dịch bảo đảm đúng ngữ nghĩa).

Table 1: Đánh giá đối đầu chất lượng dịch thuật (BLEU) và tốc độ trên FLORES-200

Chiều dịch	NLLB-600M	Qwen3-0.6B	Qwen3-1.7B
vi → en	**33.81**	18.44	26.85
en → vi	**29.67**	16.19	26.01
vi → zh	20.45	17.74	**23.41**
zh → vi	**21.07**	10.39	17.58
vi → ko	**8.05**	3.18	5.75
ko → vi	**18.60**	5.63	13.97
Tốc độ (giây/câu)	**0.4–0.9 s**	2.7–6.9 s	1.6–10.1 s

2.2 Kết luận

Căn cứ kết quả thực nghiệm đối đầu, dự án chốt giải pháp kiến trúc:

- **Chọn NLLB-200-distilled-600M:** Chiến thắng áp đảo ở **5/6 chiều dịch** và đạt tốc độ xử lý nhanh nhất ở tất cả các cặp ngôn ngữ (**0.4–0.9 s/câu**, nhanh hơn Qwen3 từ $3\times$ đến $15\times$). Kiến trúc Encoder-Decoder chuyên dụng cho dịch máy mang lại độ ổn định cao và phù hợp tối ưu hóa đồ thị tĩnh trên phần cứng nhúng.
- **Loại bỏ Qwen3-0.6B:** Mặc dù có kích thước tương đương (600M) và được hỗ trợ sẵn trên Qualcomm AI Hub, mô hình bị suy giảm chất lượng nghiêm trọng ở tất cả các chiều dịch (điển hình chiều vi → en chỉ đạt 18.44 so với 33.81 của NLLB) cùng tốc độ suy luận chậm hơn từ 3 đến 8 lần.
- **Loại bỏ Qwen3-1.7B:** Dù dẫn trước nhẹ ở riêng chiều vi → zh (23.41), mô hình thua toàn diện ở 5 chiều còn lại và có độ trễ quá lớn (lên tới 10.1 giây/câu), gây cạn kiệt hoàn toàn ngân sách thời gian thực của thiết bị biên.

3 Model NLLB

3.1 Kiến trúc Model

Nhằm khắc phục triệt để trở ngại của vòng lặp tự hồi quy (*autoregressive*) vốn đòi hỏi CPU Host phải can thiệp liên tục sau từng token, nhóm nghiên cứu đã tái cấu trúc mô hình **NLLB-200-distilled-600M** thành một **Đồ thị Tính toán Tĩnh duy nhất (Single Static DAG)** khép kín. Toàn bộ chu trình từ xử lý câu nguồn đến sinh bản dịch hoàn chỉnh được thực thi trọn vẹn trong một lượt truyền thẳng (*single-pass forward*) trên NPU Qualcomm:

$$\text{src_ids } [1,32] \xrightarrow{\text{Khối 1: Encoder}} \text{Context} \xrightarrow{\text{Khối 2: Unrolled Decoder}} \text{Bước } 1 \to \cdots \to \text{Bước } 16 \xrightarrow{\text{Khối 3: ArgMax}} \text{out_ids } [1,16]$$

1. **Khối Static Transformer Encoder ($S = 32$):** Tiếp nhận mảng định danh token câu nguồn src_ids $\in \mathbb{Z}^{1\times 32}$ (được đệm cố định bằng token pad). Khối bao gồm 12 tầng Encoder Transformer với cơ chế Multi-Head Self-Attention, chiếu toàn bộ ngữ cảnh câu nguồn sang ma trận biểu diễn không gian ẩn $H_{\text{enc}} \in \mathbb{R}^{1\times 32\times 1024}$.
2. **Khối Unrolled Autoregressive Decoder ($T = 16$ bước tĩnh):** Thay vì sử dụng vòng lặp `while` động bên ngoài, nhóm đã "trải phẳng" (*loop unrolling*) đúng 16 bước giải

mã liên tiếp ngay bên trong đồ thị ONNX:

- *Ép mã ngôn ngữ đích (Forced BOS):* Tại bước giải mã đầu tiên ($t = 1$), đầu vào được ghim cố định bằng token định danh ngôn ngữ đích (tgt_lang $\in \mathbb{Z}^1$ do người dùng lựa chọn: Tiếng Việt `vie_Latn`, Tiếng Anh `eng_Latn`, Tiếng Trung `zho_Hans`, Tiếng Hàn `kor_Hang`).
- *Lưu chuyển KV-Cache nội tại:* Ma trận Key và Value của các bước trước được lưu giữ và truyền trực tiếp giữa các tầng giải mã nội bộ bên trong bộ nhớ đệm SRAM/VTCM của NPU mà không cần truyền nhận dữ liệu qua lại với RAM hệ thống.

3. **Khối Trích chọn Từ vựng ArgMax ma trận tĩnh:** Tại mỗi bước giải mã, véc-tơ ẩn được nhân chiếu qua ma trận trọng số chia sẻ $W_{\text{lm}} \in \mathbb{R}^{1024 \times 139141}$. Phép toán argmax được thực thi song song trên tập từ vựng đã cắt tỉa để chọn ra token có xác suất cao nhất, làm đầu vào tức thì cho bước giải mã kế tiếp ($t + 1$). Đầu ra cuối cùng là tensor cố định out_ids $\in \mathbb{Z}^{1 \times 16}$.

3.2 Quantize và Deploy

Để triển khai thành công một mô hình dịch máy Sequence-to-Sequence quy mô 600 triệu tham số lên phần cứng nhúng Qualcomm Hexagon HTP v73, dự án đã áp dụng các chiến lược tối ưu chuyên sâu:

1. **Cắt tỉa Bảng từ vựng Đa ngữ (Vocabulary Pruning từ 256k xuống 139k tokens):**
   - *Thách thức giới hạn dung lượng:* NLLB-200 nguyên bản sở hữu từ điển khổng lồ 256.206 tokens phục vụ hơn 200 ngôn ngữ. Ma trận Embedding và LM Head chiếm tới hơn 50% trọng số toàn mạng, khiến tệp ONNX sau khi trải 16 bước vượt quá 3.5 GB (vượt trần giới hạn tải lên 2.0 GB của cổng Qualcomm AI Hub).
   - *Thử nghiệm cắt tỉa khắt khe:* Nhóm đã thử nghiệm lọc chỉ giữ 42.345 tokens xuất hiện trong tập ngữ liệu FLEURS; tuy nhiên kết quả chỉ đạt 31/48 câu trùng khớp so với HuggingFace gốc (bị suy thoái từ vựng nghiêm trọng).
   - *Giải pháp đột phá 139k tokens:* Nhóm quyết định bảo tồn trọn vẹn toàn bộ các ký tự và subwords thuộc 4 hệ chữ viết mục tiêu: **Latin** (Tiếng Anh, Tiếng Việt), **Hán tự** (Tiếng Trung) và **Hangul** (Tiếng Hàn). Bảng từ vựng được tối ưu về chính xác **139.141 tokens**, giúp tệp ONNX nén xuống còn **1.98 GB** (< 2.0 GB), đồng thời giữ vững độ chính xác tuyệt đối **48/48 câu kiểm chứng tương đồng 100%** so với bản gốc PyTorch.
2. **Quyết định Biên dịch Native FP16 trên Hexagon HTP v73:** Mô hình dịch máy Transformer có cấu trúc Cross-Attention đa tầng đặc biệt nhạy cảm với sai số lượng tử hóa. Thử nghiệm lượng tử hóa sau huấn luyện (PTQ W8A16) trên đồ thị unrolled khiến độ tương đồng cosin bị suy giảm. Tận dụng năng lực tính toán số thực dấu phẩy động 16-bit nguyên bản của nhân Hexagon Tensor Processor (HTP v73), nhóm cấu hình biên dịch Native FP16 với các cờ tối ưu:

`--target_runtime qnn_dlc --truncate_64bit_tensors --truncate_64bit_io`

Giải pháp này giúp **100% toán tử (7.617/7.617 layers)** được offload trọn vẹn lên NPU, triệt tiêu hoàn toàn sai số làm tròn số học và đạt tỷ lệ 0% CPU fallback.

3.3 Những khó khăn và Cách khắc phục

Quá trình đưa mô hình NLLB lên bo mạch thực tế Qualcomm Dragonwing IQ-9075 EVK đã đối mặt và giải quyết triệt để 4 vấn đề kỹ thuật then chốt:

1. **Nghẽn cổ chai vòng lặp tự hồi quy (Autoregressive Loop Bottleneck):**
   - *Nguyên nhân gốc:* Việc gọi suy luận từng bước qua API đám mây Qualcomm AI Hub mất nhiều thời gian kết nối và tạo phiên. Nếu chạy vòng lặp 15 tokens tuần tự, thời gian xử lý một câu dịch có thể kéo dài hàng chục phút, hoàn toàn bất khả thi cho ứng dụng thực tế.
   - *Giải pháp:* Đóng gói cố định $T = 16$ bước giải mã vào một đồ thị ONNX duy nhất. Máy chủ chỉ cần nộp đúng một yêu cầu suy luận duy nhất lên NPU; sau khi nhận mảng out_ids, CPU chỉ việc cắt bỏ các token rác nằm sau thẻ kết thúc câu (`EOS = 2`) và giải mã SentencePiece trong thời gian < 0.1 ms.
2. **Giới hạn Thời gian Thực thi (Maximum Execution Timeout) trên AI Hub:**
   - *Nguyên nhân gốc:* Nhóm đã thử nghiệm nâng số bước giải mã lên $T = 24$ (11.000 layers) để hỗ trợ câu dài hơn. Tuy nhiên, kích thước đồ thị quá lớn khiến Job suy luận trên AI Hub bị ngắt cưỡng bức (`FAILED: exceeded maximum execution time` sau 4.072 giây).
   - *Giải pháp:* Thực nghiệm đối chứng đa cấp độ ($T = 2, 8, 16, 24$) xác định $T = 16$ (7.617 layers) là điểm cân bằng tối ưu nhất: mô hình vừa bao phủ trọn vẹn các câu hội thoại giao tiếp thông thường, vừa chạy mượt mà trên phần cứng HTP với độ trễ chỉ 215.87 ms.
3. **Hiện tượng Sai lệch Thứ tự Đầu ra Tensor trên Qualcomm AI Hub:**
   - *Nguyên nhân gốc:* Trình biên dịch QNN của AI Hub đặt tên các tensor đầu ra theo tiền tố `output_N`. Do cấu trúc từ điển trong Python không đảm bảo sắp xếp theo thứ tự số học tự nhiên, việc đọc dữ liệu trực tiếp khiến các token bị đảo lộn vị trí trong câu dịch.
   - *Giải pháp:* Nhóm xây dựng hàm bóc tách chỉ số `int(name.split('_')[-1])` để sắp xếp lại chính xác thứ tự các tensor trước khi trích xuất kết quả mảng mã định danh token.
4. **Đứt kết nối Client trong quá trình Polling Job dài hạn:**
   - *Nguyên nhân gốc:* Do thời gian nạp mô hình nguội lần đầu của đồ thị lớn kéo dài hơn 10 phút, kết nối mạng từ máy phát triển nội bộ có thể bị gián đoạn giữa chừng khiến tiến trình chờ bị hủy (dù chip NPU trên AI Hub vẫn thực thi thành công).

- *Giải pháp:* Tích hợp cơ chế cờ môi trường `REUSE=1`, cho phép tự động truy vấn lại Target Model ID (`mqy498l5q`) đã biên dịch thành công mà không phải biên dịch lại từ đầu, tiết kiệm hơn 80% thời gian thử nghiệm.

3.4 Mã nguồn và Cách triển khai

Toàn bộ mã nguồn phát triển và thẩm định mô hình NLLB được tổ chức quy chuẩn trong thư mục `src/step4_quantization/mt/nllb/`:

1. **Hệ thống kịch bản chức năng:**
   - `step0_cpu_ref.py`: Sinh bản dịch chuẩn 8 câu đối chứng trên CPU PyTorch lưu vào `work/ref.json`.
   - `nllb_static.py`: Định nghĩa kiến trúc đồ thị tĩnh, bao gồm khối Encoder và khối giải mã T bước unrolled tích hợp sẵn KV-Cache.
   - `vocab_restrict.py` & `step3b_parity_allscripts.py`: Giải thuật cắt tỉa từ điển xuống 139.141 tokens và kiểm chứng tương đồng 48/48 câu FLEURS.
   - `step4_export.py`: Kịch bản xuất đồ thị ONNX tĩnh ($S = 32, T = 16$) ra tệp `work/nllb_S32_T16.onnx` (1.98 GB, 12.710 nodes).
   - `hub_nllb.py`: Tự động hóa kết nối Qualcomm AI Hub API: nộp biên dịch Native FP16, đo kiểm Profile hiệu năng và thực thi Inference trên phần cứng thật.
   - `results/hub_silicon_test_results_T16.json`: Nhật ký chi tiết chứa các tham số đo đạc phần cứng và chuỗi dự đoán thực tế trên chip silicon.
2. **Quy trình thực thi dòng lệnh hoàn chỉnh:**

```
# Buoc 1: Sinh ket qua tham chieu chuan CPU
python step0_cpu_ref.py

# Buoc 2: Kiem chung cat tia tu vung 139k tren tap FLEURS
python step3b_parity_allscripts.py

# Buoc 3: Xuat do thi ONNX tinh voi S=32, T=16
python step4_export.py 16

# Buoc 4: Bien dich Native FP16 va do kiem truc tiep tren Qualcomm AI Hub
python hub_nllb.py T16 work/nllb_S32_T16.onnx 16
```

3.5 Kết quả từ Qualcomm AI Hub

Đồ thị tĩnh **NLLB-S32-T16** (Target Model ID: `mqy498l5q`) đã được đo kiểm chính thức trên bo mạch **Qualcomm Dragonwing IQ-9075 EVK** thông qua nền tảng Qualcomm AI Hub:

Table 2: Đo đạc hiệu năng phần cứng NLLB-600M tĩnh trên chip Dragonwing IQ-9075

Thông số kỹ thuật phần cứng	**Giá trị thực tế trên Silicon**
Mã Job Compile	`jgd62w9lp`
Mã Job Profile	`jp1o6ly25`
Mã Job Inference	`jgd629eep`
Thời gian suy luận NPU (Inference Latency)	**215.87 ms** / câu
Dung lượng RAM đỉnh (Peak Memory)	**6.59 MB**
Thời gian nạp mô hình lần đầu (First Load Time)	865.91 s (khởi tạo bộ nhớ đệm DLC)
Tổng số toán tử trên đồ thị	7.617 layers
Tỷ lệ tính toán trên NPU (NPU Offload)	**100.0%** (7.617/7.617 layers, 0% CPU fallback)

1. Phân tích Hiệu năng Phần cứng: Thời gian suy luận thực tế trên chip chỉ **215.87 ms** cho một lượt dịch hoàn chỉnh khẳng định tính khả thi vượt bậc của kiến trúc Single Static DAG unrolled. Việc chuyển giao hoàn toàn 7.617 layers sang phần cứng Hexagon HTP v73 giúp giải phóng 100% năng lực CPU Host cho các tác vụ âm thanh và hệ thống khác. Mức chiếm dụng RAM đỉnh cực thấp (**6.59 MB**) chứng minh bộ nhớ đệm nội tại VTCM của vi xử lý Qualcomm đã được tận dụng tối đa, loại bỏ hoàn toàn hiện tượng tràn bộ nhớ.

Table 3: Đối chiếu chất lượng suy luận thực tế giữa Silicon NPU và CPU (Job: `jgd629eep`)

Hướng dịch	**Câu nguồn (Source Text)**	**Kết quả trên Silicon NPU**	**Khớp CPU**
VI → EN	Hôm nay trời đẹp quá, chúng ta cùng đi dạo nhé.	It's a beautiful day, let's go for a walk.	100%
VI → EN	Tôi muốn đặt một bàn cho hai người vào tối nay.	I want to set a table for you two tonight.	100%
EN → VI	Please turn on the lights in the living room.	Vui lòng bật đèn trong phòng khách.	100%
EN → KO	The weather today is sunny with a light breeze.	[Hangul] Oneul nalssineun haetbyeot-i jal deuneun pyeon-han baram-euro	100%
KO → EN	[Hangul] Annyeonghaseyo, oneul nalssiga jeongmal johneyo.	Hello, the weather is really nice today.	100%
ZH → EN	[Hán tự] Wo xiang yuding jinwan liang ge ren de canzhuo.	I want to book a table for two tonight.	100%
EN → ZH	Machine translation helps people communicate across languages.	[Hán tự] Jiqi fanyi bangzhu ren-men zai gezhong yuyan zhong jiaoliu.	100%
KO → VI	[Hangul] Gichayeokkkaji ga-neun gajang ppareun gil-eul allyeo juseyo.	Hãy cho tôi biết cách nhanh nhất để đến ga.	100%

2. Đánh giá Độ chính xác Dịch thuật: Kết quả đo đạc đối chứng xác nhận tỷ lệ chính xác tuyệt đối **100% (8/8 câu)** trùng khớp hoàn toàn từng token với mô hình gốc trên CPU. Mô hình xử lý chuẩn xác cả 6 hướng dịch phức tạp giữa Tiếng Việt và các ngôn ngữ tượng hình (Hán tự), ngôn ngữ chắp dính (Hangul) và tiếng Anh, hoàn toàn không xuất hiện hiện tượng biến dạng ngữ nghĩa hay lỗi suy thoái số học trên phần cứng.

4 Demo MT Dashboard

4.1 Mã nguồn và Cách triển khai

Để phục vụ công tác kiểm thử trực quan và trình diễn thực địa, dự án phát triển máy chủ điều khiển tập trung đa năng (**MT Demo Dashboard**) tích hợp mô hình dịch máy **NLLB-600M** vào một giao diện Web thời gian thực.

1. **Cấu trúc Hệ thống (`src/step4_quantization/mt/mt_demo_server.py`):**
   - *Bộ máy thực thi kép (Dual Execution Engines):*
     - **NPU Qualcomm Dragonwing (Cloud Hub):** Gửi yêu cầu suy luận trực tiếp lên chip silicon vật lý Hexagon HTP v73 (`mqy498l5q`, 7.617 layers, độ trễ đo đạc thực tế 215.87 ms).
     - **Local CPU (ONNX Runtime):** Thực thi tức thì trong khoảng 30 ms trực tiếp trên tệp `nllb/work/nllb_S32_T16.onnx` để thử nghiệm nhanh mà không phải chờ hàng đợi đám mây.
   - *Giao diện Đa ngữ Linh hoạt:* Hỗ trợ đầy đủ 6 hướng dịch hai chiều (Việt $\rightleftharpoons$ Anh, Việt $\rightleftharpoons$ Trung, Việt $\rightleftharpoons$ Hàn) cùng nút chuyển đổi chiều nhanh ($\rightleftharpoons$); tích hợp sẵn 8 câu kiểm chuẩn đối chứng FLEURS với 1 chạm để tự động điền dữ liệu.
   - *Giám sát Phần cứng Thời gian thực:* Hiển thị biểu đồ tiến trình từng giai đoạn (*Tokenize* $\rightarrow$ *Upload* $\rightarrow$ *Provisioning* $\rightarrow$ *Running on NPU* $\rightarrow$ *Detokenize*) cùng thông số độ trễ, số lớp NPU và mảng mã định danh subwords chi tiết do phần cứng sinh ra.
2. **Hướng dẫn Khởi chạy MT Dashboard:**

   a) Cách 1 – Chạy Local (Nội bộ trên máy cá nhân):

   ```
   cd src/step4_quantization/mt
   python mt_demo_server.py --port 8430
   ```

   Mở trình duyệt bất kỳ (Chrome, Edge, Firefox) và truy cập tại địa chỉ: `http://localhost:8430`.

   b) Cách 2 – Chạy Public ra ngoài Internet bằng Cloudflare Tunnel (Có HTTPS): Để trình diễn từ xa trên các thiết bị di động mà không cần mở cổng modem mạng (NAT/Port Forwarding), hệ thống tích hợp sẵn cơ chế tạo đường hầm bảo mật hoàn toàn tự động chỉ với cờ `--share`:

   ```
   python mt_demo_server.py --port 8430 --share
   ```

   Máy chủ sẽ tự động kết nối qua Cloudflare Tunnel và cung cấp đường dẫn công khai an toàn (dạng `https://*.trycloudflare.com`) để người dùng từ xa truy cập ngay lập tức.

4.2 Nhận xét kết quả

Thông qua quá trình vận hành trực tiếp MT Dashboard trên bo mạch **Qualcomm Dragonwing IQ-9075 EVK**, nhóm nghiên cứu ghi nhận 4 kết quả then chốt:

- **Độ trễ Siêu tốc Thoát khỏi Giới hạn Thời gian Thực:** Thời gian suy luận trên chip NPU chỉ tốn **215.87 ms** cho một lượt dịch hoàn chỉnh, chỉ chiếm chưa đầy 10% ngân sách trễ toàn trình (≤ 3.0 giây) của chuỗi hội thoại Speech-to-Speech (S2S), bảo đảm phản hồi tức thì giữa hai người nói.
- **Triệt tiêu Vòng lặp Tự hồi quy trên CPU (Zero-CPU Autoregression):** Nhờ cơ chế unroll đồ thị tĩnh $T = 16$ bước kết hợp tích hợp sẵn KV-Cache nội tại trong NPU, máy chủ Host hoàn toàn không phải tính toán hay duy trì vòng lặp sinh từ; thời gian hậu xử lý giải mã SentencePiece chỉ tốn < 0.1 ms.
- **Chất lượng Ngữ nghĩa Bảo toàn Tuyệt đối:** Hệ thống đạt tỷ lệ chính xác 100% (8/8 câu kiểm chứng trùng khớp từng token so với bản PyTorch CPU), chứng minh giải pháp cắt tỉa từ điển 139k tokens và biên dịch Native FP16 giữ nguyên vẹn chất lượng dịch thuật nguyên bản.
- **Sẵn sàng Tích hợp Sản phẩm Biên (Edge Gateway Ready):** Máy chủ xây dựng trên FastAPI không đồng bộ, vận hành ổn định với mức chiếm dụng tài nguyên tối thiểu, sẵn sàng kết nối trực tiếp với luồng văn bản từ module ASR và chuyển giao kết quả sang module TTS trong chuỗi pipeline khép kín.

5 Pipeline Integration

5.1 Các Modules còn lại

Bên cạnh khối Dịch máy (MT) đã được tối ưu hóa đồ thị tĩnh trên NPU, hệ thống phiên dịch giọng nói toàn trình (Speech-to-Speech – S2S) tích hợp đồng bộ 3 phân hệ liên hoàn:

- **Audio Front-end (Step 0):** Mô hình DeepFilterNet3 kết hợp thuật toán VAD (Voice Activity Detection), đảm nhận lọc sạch tạp âm môi trường công nghiệp độ ồn cao (70–95 dB SPL) và trích xuất các phân đoạn giọng nói sạch trước khi chuyển vào ASR.
- **Nhận dạng Giọng nói Đa ngữ – ASR (Step 1):** Kiến trúc 2 động cơ vận hành 100% NPU-native trên Hexagon NPU: **Zipformer-150M-CR-CTC** cho Tiếng Việt (Single Static DAG, độ trễ 184.31 ms cho 15 giây âm thanh) và **SenseVoice-Small** cho Ngoại ngữ (Split-Graph W8A16, độ trễ 269.40 ms cho 29 giây âm thanh, RTF = 0.0093), cung cấp văn bản đầu vào tức thì cho MT.
- **Tổng hợp Giọng nói – TTS (Step 3):** Chuyển đổi văn bản sau dịch từ MT thành giọng nói tự nhiên: **Piper TTS** cho Tiếng Việt (ONNX tĩnh, RTF siêu tốc 0.144), **Supertonic 3** cho Tiếng Anh và Tiếng Hàn, cùng **MeloTTS** cho Tiếng Trung.

Toàn bộ hệ thống sau khi nén chỉ chiếm ≈ 1.38 GB bộ nhớ lưu trữ, nằm gọn trong dung lượng RAM của bo mạch Qualcomm Dragonwing IQ-9075 EVK.

5.2 Hướng hợp nhất Pipeline

Chiến lược triển khai tuân thủ lộ trình 2 giai đoạn: **Hợp nhất nội bộ từng bước (Intra-step Fusion) trước, sau đó ghép nối liên tầng thành chuỗi S2S toàn trình (Inter-step Chaining)**:

1. Pha 1 – Hợp nhất Nội bộ Từng Bước (Intra-step Fusion):

- *Khối ASR:* Hợp nhất toàn bộ Fbank DSP, Encoder, CTC Head và bộ Detokenizer UTF-8 thành đồ thị tĩnh duy nhất chạy 100% NPU.
- *Khối MT:* Tĩnh hóa kích thước ngữ cảnh và nhúng bảng tra cứu Language ID vào đồ thị QNN DLC của NLLB-200.
- *Khối TTS:* Đóng gói liên hoàn Text Encoder, bộ tạo phổ Mel và Vocoder thành một chuỗi tính toán nội bộ duy nhất, xuất thẳng sóng âm PCM 16 kHz.

2. Pha 2 – Ghép nối Toàn trình & Kiểm định Liên tầng (Inter-step Chaining):

$$\text{Audio Vào} \xrightarrow{\text{Step 0: Lọc nhiễu}} \text{Step 1: ASR} \xrightarrow{\text{Step 2: Dịch MT}} \text{Step 3: Tổng hợp TTS} \rightarrow \text{Audio Ra}$$

- *Truyền dữ liệu Zero-copy:* Các bước trao đổi dữ liệu bất đồng bộ qua bộ đệm tuần hoàn (*Circular Buffer*) trên RAM LPDDR5 theo mô hình Producer–Consumer, triệt tiêu độ trễ I/O.
- *Cơ chế kiểm soát chất lượng liên tầng:* Tự động hạ chữ thường (`hyp.lower()`) từ Zipformer trước khi nạp vào MT để bảo toàn mã hóa BPE; đồng thời dùng SenseVoice nhận diện ngược âm thanh TTS để tự động sinh lại nếu phát hiện lỗi lặp âm tiết.
- *Ngân sách độ trễ toàn trình (Latency Budget):* Tổng thời gian xử lý toàn chuỗi chỉ tốn 1.0–1.8 giây (ASR ~ 0.2 s, MT ~ 0.6 s, TTS ~ 0.5 s), hoàn toàn nằm dưới giới hạn khắt khe ≤ 3.0 giây của OneVoice AI Challenge.